

Exploración de género en Arxiv

1. INTRODUCCIÓN

¿En matemática hay algún tipo de sesgo de género de acuerdo a las subdisciplinas? Para analizar esta pregunta sería útil aportar datos objetivos, como por ejemplo determinar cuál es el porcentaje de mujeres y varones que publican en cada área. Por supuesto que esto no responderá la pregunta pero nos brindará información objetiva.

Igual se puede argumentar todo el tema de los géneros fluidos y etc. Pido disculpas al colectivo LGBTI+, entiendo que mucho de esto se está discutiendo, y mientras tanto sólo haré una exploración binaria (no sabría cómo encarar otra).

Con este nuevo norte se abren nuevos interrogantes. En primer lugar, como ocurre en todas las ciencias, no hay una base de datos completa, al alcance de la mano, donde se encuentren *todas* las publicaciones en *todas* las subdisciplinas. Se puede buscar por editorial, por país, pero obtener esas bases de datos sería un nuevo desafío. Es un proyecto ambicioso, pero podemos intentar centrarnos en lo que sí está a nuestro alcance: en matemática está muy extendido el uso del repositorio arXiv (<https://arxiv.org/>). Y se puede acceder a él libremente.

2. DESARROLLO

Nos basamos en dos puntos clave: el módulo arxiv para Python (que permite desde Python explorar el repositorio), y un módulo que, dado un nombre, "adivina" el género. Como éste último hay varios, utilicé el primero que apareció en Google (y que más o menos pude entender). No es óptimo, no puede decidir para nombres asiáticos principalmente, y además como es esperable, hay nombres que son unisex.

Este script encuentra en arxiv las abreviaturas y los nombres completos de las categorías que el repositorio tiene para las diversas subdisciplinas de la matemática, y para cada categoría corre el script para obtener los nombres completos de cada autor, chequea el género y lleva la cuenta (incluyendo las respuestas ambiguas y desconocidas), y arma una tabla.

Para hallar las abreviaturas recurrí a un web scraper que adapté para este caso. Luego armé un bucle con el script pulido donde se explora la categoría, se obtienen los nombres de cada autor de cada artículo, se separa el primer nombre y se le detecta el género. A su vez, se actualiza un contador de acuerdo a "varones", "mujeres", "nombre andrógino" y "desconocido". Estos datos los guarda en un dataframe y para finalizar muestra algunas visualizaciones posibles de los mismos.

3. OBSERVACIONES

La exploración del repositorio arxiv es muy compleja y lleva bastante tiempo. En la web está documentado cómo se estima el tiempo. Es monstruosa la cantidad de datos, es esperable que correr el script sin demasiadas restricciones lleve unos cuantos minutos. Por eso presento una "versión corta" donde por cada categoría se fija la cantidad de resultados máximos que se requieren.

Para bajar la ansiedad de la espera, agregué un contador y algunos textos que van indicando por dónde va la exploración y los resultados parciales. Todo es opcional, el script podría correr tranquilamente sin todo ese código y obtener los mismos resultados.

No estoy satisfecha con las visualizaciones obtenidas, ni con el pobre/nulo análisis de la tabla.

Por último, creo que el script es bastante versátil en cuanto a disciplinas de arxiv (por ejemplo para Física se podría implementar con muy pocos cambios). También en cuanto al repositorio: tengo en mente ver si puedo hacer algo similar con ZentralBlatt (que es específico de matemática, y no tiene artículos completos sino reviews de los mismos), si es que tiene un módulo para Python o quizás haciendo web scraping más avanzado.

En cuanto al detector de género, quizás también podría intentar implementar otro.